



Monitoring, Logging & Observability

AICB-P1 · Ngày 13 · Biết agent đang hoạt động thế nào

Tên Giảng Viên

VinUniversity · Phase 1 · 2026

HÃY SUY NGHĨ...

“3 câu chuyện có thật: CFO hỏi vì sao hóa đơn OpenAI tháng này \$45,000 — không ai trả lời được. Chatbot ngân hàng viral lên Twitter vì trả lời xúc phạm — phát hiện sau 6 giờ. Agent chạy “bình thường” nhưng engagement giảm 30% suốt 2 tuần — không alert nào fire.”

Giữ câu hỏi này trong đầu khi học bài hôm nay

1. Foundations: Observability & 3 pillars
2. AI metrics deep dive (TTFT, quality, cost, drift)
3. Structured logging (schema, PII, aggregation)
4. Distributed tracing (OpenTelemetry, Langfuse)
5. SLO-based alerting & dashboard design
6. Tools landscape 2026 + case studies
7. Lab 13: monitoring blueprint cho agent
8. Preview Day 14: Evaluation with RAGAS

- **Remember** — liệt kê được 3 pillars of observability và 6 loại AI-specific metrics
- **Understand** — giải thích được vì sao P99 quan trọng hơn average, và SLO khác SLA thế nào
- **Apply** — implement được structured logging với correlation ID + PII sanitization cho agent đang deploy
- **Analyze** — đọc được trace waterfall và xác định bottleneck trong agent pipeline nhiều bước
- **Evaluate** — so sánh được Langfuse / LangSmith / Helicone / Phoenix cho use case cụ thể
- **Create** — thiết kế được monitoring blueprint với SLO, alert rules, và dashboard 3 layers

Monitoring blueprint hoàn chỉnh cho deployed agent: structured logging + tracing + dashboard + alert rules dựa trên SLO.

- 1 structured logging pipeline: JSON, correlation ID, PII sanitized, 3 log levels
- 1 Langfuse/LangSmith integration: ≥ 10 traces với cost + latency + quality tags
- 1 monitoring dashboard: 4 golden signals + cost + quality (6 panels tối thiểu)
- 1 SLO definition + alert rules: symptom-based, có runbook link
- 1 trang blueprint document: mô tả SLO, architecture diagram, alert playbook

Foundations of Observability

Từ lý thuyết xuống thực hành: observability là gì, và vì sao chỉ monitoring không đủ cho AI agent


Monitoring (biết trước)

- Đo các metrics **biết trước** sẽ cần
- Trả lời câu hỏi **đã định sẵn**
- Phù hợp với *known-unknowns*
- Ví dụ: CPU > 80%? uptime?

Observability (khám phá)

- Hệ thống phát ra đủ **data** để hỏi câu hỏi **mới**
- Phù hợp với *unknown-unknowns*
- Ví dụ: vì sao user X với feature Y, model Z, tháng W latency cao?

AI agent có rất nhiều **unknown-unknowns** (prompt mới, model drift, user creativity)
→ observability quan trọng hơn monitoring đơn thuần.



MTTD (Mean Time To Detect): từ khi sự cố xảy ra đến khi phát hiện.

MTTR (Mean Time To Recover): từ khi phát hiện đến khi fix xong.

Monitoring tốt = **giảm MTTD xuống phút**, không phải ngày. Không có observability, MTTD = thời gian user phản ánh.

Day 12 đã làm được

- Agent deployed trên cloud
- Public URL hoạt động
- Health check endpoint
- Basic authentication

Nhưng chưa trả lời

- Agent đang chậm hay nhanh? P99?
- Tốn bao nhiêu tiền mỗi user/ngày?
- Bao nhiêu request fail, và loại lỗi gì?
- Câu trả lời có đúng không?
- Khi nào cần scale up?

Lưu ý: Không có monitoring, bạn chỉ biết agent hỏng **khi user phàn nàn**. Với AI agent, user thường không phàn nàn — họ **im lặng churn**.

Metrics

Đo lường

Bao nhiêu?
Bao lâu?
Latency, rate, cost

Logs

Ghi chép

Gì xảy ra?
Input/output, event

Traces

Theo dõi

Tại sao?
End-to-end flow

Profiles

Phân tích CPU

Tồn ở dòng
code nào?
Rare in AI

Metrics = số liệu aggregate (rẻ, alert). **Logs** = event chi tiết (đắt, debug). **Traces** = hành trình request (vừa phải, root-cause).

Pillar thứ 4 **Profiles** (CPU/memory) ít dùng cho AI vì bottleneck thường ở LLM API, không code local.

Cardinality = số tổ hợp unique của các label.

Ví dụ: metric `llm_latency` có labels:

- `user_id`: 100,000 giá trị
- `model`: 4 giá trị
- `endpoint`: 20 giá trị
- `status`: 10 giá trị

Tổng series = $100,000 \times 4 \times 20 \times 10 = 8 \times 10^7$ series!

Với Prometheus, mỗi series ≈ 500 bytes/15s $\rightarrow$ ~**40GB/giờ**. Không khả thi.

Quy tắc cardinality

- **KHÔNG** dùng `user_id`, `request_id`, `email` làm metric label
- **CÓ** dùng: `model`, `env`, `feature`, `tier`
- High-cardinality data $\rightarrow$ vào **logs** hoặc **traces**
- Sampling 1–10% cho AI workloads

Lưu ý: Sai cardinality là cách phổ biến nhất làm **sập Prometheus** và nhận bill \$40k/tháng từ Datadog không báo trước.

Kịch bản: Alert fire lúc 3h sáng: “P99 latency > 8s suốt 10 phút”.

1. **Metrics** cho thấy P99 đã tăng từ 2s → 8s trong 10 phút. Error rate vẫn 0%.
→ *Biết có vấn đề, nhưng chưa biết vì sao.*
2. **Traces** cho 10 request chậm nhất: span vector_search chiếm 6.5s (bình thường 200ms).
→ *Bottleneck tại retrieval, không phải LLM.*
3. **Logs** tại service retrieval: ``Pinecone request timeout after 6000ms`` bắt đầu từ 02:47.
→ *Root cause: Pinecone có sự cố, cần chuyển sang fallback vector DB.*

Metrics → phát hiện. Traces → localize. Logs → root cause. Thiếu 1 trong 3, MTTR sẽ kéo dài từ phút lên giờ.

Agent trả lời sai, không ai biết. Đến khi phát hiện thì đã mất user.

Token cost tăng dần không alert. Cuối tháng bill gấp 5 lần dự kiến.

Latency P95 tăng 10ms/tuần. 6 tuần sau: 2x chậm hơn. Không baseline → không ai để ý.

“Agent sai hôm qua.” Không log, không trace. Không reproduce → không fix.

Lưu ý: Air Canada 2024: chatbot tư vấn sai chính sách, tòa buộc trả tiền theo câu chatbot. Không monitoring = không phòng vệ.

Thuật ngữ	Định nghĩa	Ví dụ cho agent
SLI	Service Level Indicator — 1 metric đo lường được	P95 latency = 2.3s
SLO	Objective: mục tiêu nội bộ cho SLI	$P95 \leq 3s$ trong 99.5% thời gian (28 ngày)
SLA	Agreement: cam kết với khách hàng, có phạt	99% uptime, nếu không sẽ re-fund 10%
Error Budget	Dung sai cho phép SLO sai lệch	$100\% - 99.5\% = 0.5\% = 3.6$ giờ/tháng

SLO **chặt hơn** SLA (buffer để không bao giờ breach SLA). Khi error budget còn nhiều → được phép deploy risky. Hết budget → freeze, chỉ fix bug.

SLO		Downtime/tháng	Downtime/tuần	Downtime/ngày
99%		7.2 giờ	1.68 giờ	14.4 phút
99.5%		3.6 giờ	50.4 phút	7.2 phút
99.9%	(3	43.2 phút	10.1 phút	1.44 phút
nines)				
99.99%	(4	4.32 phút	1.01 phút	8.6 giây
nines)				
99.999%	(5	25.9 giây	6.05 giây	0.86 giây
nines)				

Lưu ý: Mỗi thêm 1 “nine” tổn gấp 10 lần tiền. AI agent thực tế → SLO **99%–99.5%** là đủ. Đừng hứa 99.99% khi LLM API chỉ 99.9%.

Google SRE — 4 Golden Signals

1. **Latency** — thời gian phản hồi
2. **Traffic** — request rate (QPS)
3. **Errors** — error rate
4. **Saturation** — tài nguyên còn bao nhiêu?

AI Agent cần thêm 2

5. **Cost** — \$/request, \$/user, token usage
6. **Quality** — hallucination rate, user CSAT, groundedness score

Agent có thể “up” (traffic OK, latency OK, error OK) nhưng **trả lời sai** và **đốt tiền**. Đây là 2 failure mode riêng của AI mà monitoring truyền thống bỏ qua.

RED (request-centric)

- **Rate** — requests/giây
- **Errors** — error rate
- **Duration** — latency P50/P95/P99

Perspective: user — tôi gửi request, được gì?

USE (resource-centric)

- **Utilization** — tài nguyên dùng %
- **Saturation** — có queue/chờ không?
- **Errors** — lỗi của resource

Perspective: resource — LLM API, queue đang làm gì?

Agent chậm (RED: Duration P95 tăng) → debug bằng USE (LLM rate limit utilization 95%) → bị throttle → upgrade tier hoặc fallback.

AI Metrics Deep Dive

AI agent cần metrics riêng: performance, quality, cost, reliability, và drift — những thứ monitoring truyền thống không có

02

Metrics truyền thống

- **Latency** — thời gian end-to-end
- **Throughput** — requests/giây
- **Queue depth** — backlog
- **Uptime** — availability

AI-specific (mới)

- **TTFT** — Time To First Token
- **TPOT** — Time Per Output Token
- **Tokens/sec** — tốc độ generate
- **Context fill %** — dùng bao nhiêu window

Với streaming UI, user cảm nhận **TTFT**, không phải total latency. TTFT 500ms → nhanh kể cả tổng 8s. TTFT 3s → lag kể cả tổng 4s. Optimize TTFT trước total.

Bài toán: Agent có $P99 = 5s$, user chat 10 lượt.

Xác suất user gặp ≥ 1 lần $> 5s$:

$$P = 1 - 0.99^{10} \approx 9.6\%$$

- 1/10 user sẽ gặp lag rất tệ
- Với 1,000 user/ngày $\rightarrow$ 96 user bức xúc
- Họ sẽ là người tweet negative, churn, complain

Amazon Rule

“Every 100ms of latency cost them 1% of sales.”

$\rightarrow$ Optimize **tail**, không chỉ average.

$\rightarrow$ P99, P99.9 là KPI chính thức tại Amazon, Google, Meta.

Service có $P99 = X$ ms, user dùng N lượt $\rightarrow$ khả năng gặp tail $= 1 - 0.99^N$. **Tail latency compounds nhanh** trong agentic workflow nhiều bước — 5 bước $\times$ P99 = P95 của toàn bộ!

P50

P50 = 800ms (nửa số request nhanh hơn)


P95

P95 = 2.1s (95% request nhanh hơn)

P99

P99 = 5.3s

Lưu ý: Trung bình (average) ẩn giấu long tail. Nếu P50 là 800ms nhưng P99 là 5s, nghĩa là **1 trên 100 user phải chờ rất lâu** — và họ là người dễ churn nhất.



L1 rẻ, realtime nhưng không nói được quality thực. L4 là ground truth nhưng lag hàng tuần. **Production** cần cả 4 — L1/L2 để alert, L3/L4 để confirm trends.

Hallucination = agent trả lời “rất tự tin” nhưng sai sự thật. Không có 1 metric duy nhất → cần combo 4 patterns:

Pattern 1: Groundedness (RAG)

- Mỗi claim trong output, check có trong retrieved context không
- Tool: RAGAS faithfulness, TruLens

Pattern 2: Self-consistency

- Gọi LLM 3 lần với temp = 0.7
- Nếu 3 câu trả lời mâu thuẫn → nghi ngờ
- Cost $3\times$ → dùng cho sample 1%

Pattern 3: Entity verification

- Extract entities (tên, số, dates)
- Cross-check với DB/API đáng tin
- Cho finance, medical use cases

Pattern 4: User feedback loop

- “Was this helpful?” button
- Regenerate click = tín hiệu hallucination
- Signal chậm nhưng rẻ và thật

Lưu ý: Air Canada revisited: Chatbot tư vấn chính sách bereavement fare **không tồn tại**. Nếu có groundedness check với actual policy DB → block câu trả lời từ đầu, tránh kiện tụng.

Cost per request không phải 1 con số đơn giản:

$$\text{Cost}_{req} = \underbrace{\frac{T_{in}}{10^6} \cdot P_{in}}_{\text{input cost}} + \underbrace{\frac{T_{out}}{10^6} \cdot P_{out}}_{\text{output cost}} + \underbrace{\frac{T_{cache}}{10^6} \cdot P_{cache}}_{\text{cache read}}$$

Ví dụ: Claude Sonnet 4.5 (2026)

- Input: \$3 / M tokens
- Output: \$15 / M tokens
- Cache write: \$3.75 / M
- Cache read: \$0.30 / M (**10x rẻ hơn input**)

Request điển hình: RAG agent

- System + docs: 8,000 tokens in
- User query: 200 tokens in
- Response: 500 tokens out
- $\text{Cost} = 8200 \cdot \frac{3}{10^6} + 500 \cdot \frac{15}{10^6}$
- $= \$0.0246 + \$0.0075 = \mathbf{\$0.032/req}$

Với 100k requests/ngày, cost = \$3,200/ngày = **\$96k/tháng**. Nếu prompt cache hit 80% cho system: giảm còn \$1,100/ngày = tiết kiệm **\$63k/tháng**.

Câu hỏi CFO luôn hỏi: “\$50k tháng này, ai tốn?” — bạn phải attribute được.

Dimension	Tag gắn vào trace	Dùng để...
Per user	user_id	Biết power user, tính pricing
Per feature	feature="summary"	Prioritize optimization
Per model	model="claude-sonnet-4-5"	So sánh cost/value các model
Per tenant	tenant_id	Multi-tenant billing
Per env	env="prod"	Tách dev/staging noise
Per cohort	plan="enterprise"	Margin analysis

Mọi LLM call phải có **3 tags tối thiểu**: user_id, feature, model. Thiếu 1 trong 3 → khi CFO hỏi, bạn không trả lời được, và ngân sách bị cắt.

1. Prompt Caching

Cache system prompt + docs tĩnh. Anthropic: **10x** rẻ hơn cache read. → **giảm 70% cost**

2. Model Routing (Cascade)

Dễ → Haiku. Khó → Sonnet. Classifier nhẹ quyết định. → **40–60% giảm cost**

3. Semantic Cache

Query tương tự → trả lời cached (embedding similarity > 0.95). → **Hit rate 20–40%**

4. Batch API

Non-realtime (summary đêm) → batch giá **50%**. → **50% offline work**

Apply cả 4 patterns: \$96k/tháng → \$22k/tháng (77% tiết kiệm). Đây là **FinOps for AI** — kỹ năng hot 2026.

“Error rate 5%” — nhưng loại lỗi gì? Không taxonomy → không fix được.

Loại lỗi	Nguyên nhân	Cách handle
LLM API 5xx	Provider down/rate limit	Retry exponential backoff, fallback model
LLM timeout	Slow provider, network	Circuit breaker, client timeout < server
Tool call failed	External API lỗi	Retry, graceful degradation
Tool schema invalid	LLM sinh JSON lỗi	Re-prompt với error feedback
Guardrail block	Content policy vi phạm	Log + user-friendly message
Empty response	LLM refuse/filter	Alternate prompt, escalate to human
Context overflow	Input > limit	Truncate, summarize history

Track **error_type** field trong mỗi log. Alert fire → biết ngay gọi ai (LLM provider? tool owner? prompt engineer?).

Engineering metrics xanh không có nghĩa là user happy. Cần đo trực tiếp:

Explicit signals

- **Thumbs up/down** — gắn vào mỗi response
- **CSAT survey** — weekly sample
- **NPS** — quarterly
- **Escalation to human** — rate

→ *Signal rõ, response rate thấp ($< 5\%$)*

Implicit signals (quan trọng hơn)

- **Regenerate rate** — user bấm “thử lại”
- **Session length** — dùng lâu = hài lòng?
- **Follow-up rate** — câu hỏi tiếp
- **Conversion** — action sau chat
- **Return rate** — quay lại trong 7 ngày

Họ thấy Regenerate rate là **predictor tốt nhất** cho churn — hơn cả thumbs down. User không bấm thumbs down, họ chỉ... rời đi.

3 loại drift cần monitor:

- **Data drift** — input distribution thay đổi (user hỏi kiểu mới)
- **Concept drift** — mapping input→output thay đổi (luật mới)
- **Model drift** — provider update model, behavior đổi

Phát hiện bằng:

- Population Stability Index (PSI)
- KL-divergence giữa distributions
- Embedding drift (cosine similarity)

PSI formula

$$PSI = \sum_i (p_i - q_i) \ln \frac{p_i}{q_i}$$

Interpret:

- < 0.1 — stable
- $0.1-0.25$ — mild drift
- > 0.25 — significant, cần retrain

Lưu ý: Case 2024: OpenAI silently update GPT-4 → format output đổi → nhiều pipelines breaks in silence. Không drift monitoring = không biết.

Stakeholder	Quan tâm	Metrics
Engineering	System health, debug	Latency P95/P99, error rate, tool call failure, saturation
Product	User experience	CSAT, task completion, hallucination rate, re-generate rate
Finance / Ops	Cost control	Cost/day, tokens/request, cost by model, attribution
Leadership	ROI overview	Adoption rate, cost vs value, uptime, user growth
Security / Legal	Compliance	PII leak rate, audit log completeness, data retention

Dashboard cho stakeholders phải nói bằng **ngôn ngữ business**. “P95 = 2.1s” → “95% user nhận trả lời trong 2s”.

Structured Logging

Biến log thành **data** có thể query được — nền tảng cho debug AI agent ở scale

03

```
# --- Unstructured: kho search, kho filter ---  
# 2026-03-18 10:23:45 INFO Agent responded to query  
# 2026-03-18 10:23:46 ERROR Tool call failed  
  
# --- Structured JSON: de query, de aggregate ---  
log_entry = {  
    "ts": "2026-03-18T10:23:45Z",  
    "level": "INFO",  
    "correlation_id": "req-abc123",  
    "user_id": "u_7842",  
    "event": "agent_response",  
    "latency_ms": 1250,  
    "tokens_in": 850, "tokens_out": 120,  
    "cost_usd": 0.0043,  
    "model": "claude-sonnet-4-5",  
    "feature": "summary"  
}
```


Tier 1: Required

Mỗi log entry **phải** có:

- ts (ISO 8601)
- level (INFO/WARN/ERROR)
- correlation_id
- service name
- event type

Tier 2: Context

Nên có khi liên quan:

- user_id (hashed)
- session_id
- feature
- model
- env

Tier 3: Payload

Event-specific metrics:

- latency_ms
- tokens_in/out
- cost_usd
- error_type
- tool_name

Viết thành Pydantic model hoặc JSON Schema, validate trước khi emit. Nếu mỗi service log khác nhau → dashboard không build được.

```
import structlog, logging

structlog.configure(
    processors=[
        structlog.contextvars.merge_contextvars,
        structlog.processors.add_log_level,
        structlog.processors.TimeStamper(fmt="iso", utc=True),
        structlog.processors.StackInfoRenderer(),
        structlog.processors.format_exc_info,
        structlog.processors.JSONRenderer(),
    ],
    wrapper_class=structlog.make_filtering_bound_logger(logging.INFO),
    cache_logger_on_first_use=True,
)

log = structlog.get_logger()
log.info("agent_started", service="rag-agent", version="1.2.0")
# --> {"event": "agent_started", "level": "info", "timestamp": "..."}

```

```
from structlog.contextvars import bind_contextvars, clear_contextvars
import uuid

async def handle_request(request):
    clear_contextvars()
    bind_contextvars(
        correlation_id=str(uuid.uuid4())[:8],
        user_id=request.user_id, feature=request.feature,
    )
    # Tu đây tro đi, mọi log.* tu động có 3 fields này
    log.info("request_received", query_len=len(request.query))
    result = await agent.run(request.query)
    log.info("response_sent", latency_ms=result.latency)
    return result
```

contextvars an toàn với asyncio — mỗi request có context riêng, không bị lẫn giữa



`correlation_id = "req-abc123"`

Mọi log entry đều có field này → grep 1 ID ra full journey

HTTP header traceparent (W3C Trace Context) = correlation ID chuẩn quốc tế. Mọi framework hiện đại (FastAPI, Express) đều support.

Nên log

- Input **đã sanitize** (độ dài, topic)
- Output summary (không full text)
- Tool calls + results (metadata)
- Latency, tokens, cost
- Errors + stack traces
- Correlation ID, hashed user ID

KHÔNG log

- PII (tên, SĐT, CCCD, email)
- Full prompt chứa sensitive data
- API keys, tokens, secrets
- Credit card, bank account
- Full raw user input
- DEBUG verbose ở production

Lưu ý: Log PII = vi phạm GDPR, PDPA, CCPA. Phạt có thể **4% revenue toàn cầu** (GDPR). Sanitize **trước** khi log, không phải sau khi bị audit.

```
# --- Cach 1: regex nhanh cho common patterns ---
import re
PII_PATTERNS = {
    "email": r"[\w\.-]+@[ \w\.-]+\.\w+",
    "phone_vn": r"(\+84|0)\d{9,10}",
    "cccd": r"\b\d{12}\b",
    "credit_card": r"\b\d{4}[- ]?\d{4}[- ]?\d{4}[- ]?\d{4}\b",
}

def scrub(text):
    for n, p in PII_PATTERNS.items():
        text = re.sub(p, f"[REDACTED_{n.upper()}] ", text)
    return text

# --- Cach 2: Microsoft Presidio (NER-based, robust) ---
from presidio_analyzer import AnalyzerEngine
from presidio_anonymizer import AnonymizerEngine
analyzer, anonymizer = AnalyzerEngine(), AnonymizerEngine()
results = analyzer.analyze(text=user_input, language="en")
safe = anonymizer.anonymize(text=user_input, analyzer_results=results).text
```

Level	Khi nào dùng	Ví dụ	Prod?
DEBUG	Dev only, rất chi tiết	Full prompt, intermediate state	Không (sample 1%)
INFO	Normal flow, milestone events	Request received, response sent	Có
WARN	Degraded nhưng vẫn hoạt động	Retry succeeded, fallback used	Có
ERROR	Failed, cần attention	Tool call timeout, LLM error	Có, alert
CRITICAL	System-level failure	DB unreachable, all models down	Có, page

Production chạy **INFO**. Debug cụ thể: tạm bật DEBUG cho request ID đó, xong tắt. Không để DEBUG luôn-on → log volume 100x, bill lên trời.

Vấn đề: $100k \text{ requests/ngày} \times 10 \text{ log entries/request} = 1M \text{ entries/ngày}$. Elastic/Datadog tính $\$0.10/1k \text{ entries} \rightarrow \$100/\text{ngày}$ chỉ riêng log. Không scalable.

Strategies

- **Head sampling** — quyết định sample ngay khi trace bắt đầu (rẻ, có thể miss errors)
- **Tail sampling** — quyết định sau khi trace xong (đắt, giữ được 100% errors)
- **Reservoir sampling** — giữ N mẫu uniform

Strategy điển hình cho AI agent

- 100% ERROR và WARN
- 10% INFO (cho normal requests)
- 1% DEBUG (cho deep debug)
- 100% requests $> 10s$ (tail-sampling on latency)
- 100% cost $> \$1/\text{request}$ (outliers)

Sampling giảm cost 10–100x, nhưng mất visibility vào normal pattern. Giữ 100% errors là non-negotiable — đó là data debug quan trọng nhất.

Stack	Components	Khi nào dùng	Cost/tier
ELK	Elasticsearch, Logstash, Kibana	Full-text search mạnh, complex queries	Tự host, OSS
Loki	Loki, Promtail, Grafana	Label-based (giống Prometheus), rẻ	Tự host, OSS
Datadog Logs	SaaS	Setup nhanh, alert tốt, đắt ở scale	\$0.10/GB
CloudWatch	AWS native	Đã ở AWS, tích hợp IAM	\$0.50/GB ingest
BigQuery	GCP DW	Analytics SQL, long retention	\$0.02/GB scan

Langfuse tự là log store cho LLM calls + SaaS free tier. Dev local → stdout JSON + jq là đủ. Scale up mới cần ELK/Loki.

Audit log = record **who did what when** cho compliance, legal, security.

App log

- Mục đích: debug, performance
- Retention: 30–90 ngày
- Có thể sample
- Có thể sửa/xóa
- Truy cập: dev team

Audit log

- Mục đích: compliance, forensics
- Retention: **2–7 năm** (tùy ngành)
- **Không sample** — 100%
- **Append-only** — không sửa được
- Truy cập: restricted (compliance officer)

Lưu ý: Sai lầm phổ biến: trộn audit log vào app log → khi cần investigate bị thiếu data. Tách riêng từ ngày đầu: S3 bucket với Object Lock, hoặc dedicated audit service.

Distributed Tracing

Trace cho biết toàn bộ hành trình của 1 request qua nhiều bước
— công cụ số một để debug AI agent pipeline

04


Khái niệm cốt lõi

- **Trace** — toàn bộ request end-to-end, có `trace_id` duy nhất
- **Span** — 1 đơn vị công việc trong trace, có `span_id`, `parent_span_id`
- **Context propagation** — cơ chế truyền `trace_id` qua boundaries (HTTP headers, queue messages)

Span có gì?

- `name` — tên operation (e.g. `llm.generate`)
- `start_time`, `duration`
- `attributes` — key-value (model, tokens)
- `status` — OK / ERROR
- `events` — logs gắn vào span
- `links` — related spans (e.g. `retry`)

Trace = cây. Root span là entry point (HTTP request). Child spans là các bước con (RAG retrieve, LLM call, tool call). Nhìn cây biết bottleneck.



Mỗi hàng ngang là 1 **span**. Tất cả spans của 1 request tạo thành 1 **trace**. Nhìn trace biết ngay **bottleneck ở đâu**.

OpenTelemetry (OTel) = CNCF graduated project (2024), vendor-neutral tiêu chuẩn cho observability.

OTel gồm 3 phần

- **API** — interface để instrument code (ngôn ngữ-agnostic)
- **SDK** — implementation cho ngôn ngữ cụ thể (Python, Go, Java...)
- **Collector** — receive, process, export data đến backend (Jaeger, Tempo, Datadog...)

Vì sao quan trọng

- Instrument **1 lần** — switch backend tự do (khỏi vendor lock-in)
- Auto-instrumentation cho FastAPI, requests, SQLAlchemy...
- 2024: OTel phát hành **GenAI Semantic Conventions** cho LLM tracing

Học OTel một lần → dùng được Langfuse, Datadog, Jaeger, New Relic đều được. Tất cả đều accept OTLP protocol.

```
from opentelemetry import trace
from opentelemetry.sdk.trace import TracerProvider
from opentelemetry.sdk.trace.export import BatchSpanProcessor
from opentelemetry.exporter.otlp.proto.http.trace_exporter import OTLPSpanExporter

# Setup 1 lan o startup
provider = TracerProvider()
provider.add_span_processor(BatchSpanProcessor(OTLPSpanExporter()))
trace.set_tracer_provider(provider)
tracer = trace.get_tracer("agent-service")

# Instrument function
def rag_retrieve(query):
    with tracer.start_as_current_span("rag.retrieve") as span:
        span.set_attribute("rag.query_len", len(query))
        results = vector_db.search(query)
        span.set_attribute("rag.result_count", len(results))
    return results
```

Tiêu chuẩn từ 2024: mọi LLM trace **nên** dùng các attribute names này → tool vendor-agnostic hiểu được.

Attribute	Ý nghĩa
<code>gen_ai.system</code>	Provider: “anthropic”, “openai”, “google”
<code>gen_ai.request.model</code>	Model name: “claude-sonnet-4-5”
<code>gen_ai.request.temperature</code>	Sampling temp
<code>gen_ai.request.max_tokens</code>	Max tokens cap
<code>gen_ai.usage.input_tokens</code>	Input tokens
<code>gen_ai.usage.output_tokens</code>	Output tokens
<code>gen_ai.response.finish_reasons</code>	“stop”, “length”, “tool_use”
<code>gen_ai.operation.name</code>	“chat”, “completion”, “embeddings”

Dùng namespace `gen_ai.*` → dashboard queries reusable. Tránh custom names như `my_model` — không interoperable.



```
# --- Install ---
# pip install opentelemetry-distro opentelemetry-exporter-otlp \
#   opentelemetry-instrumentation-fastapi opentelemetry-instrumentation-anthropic

# --- Run (không cần sửa code) ---
# opentelemetry-instrument --traces_exporter otlp uvicorn app:main

# --- app.py: code thông thường, không có OTel boilerplate ---
from fastapi import FastAPI
from anthropic import Anthropic
app = FastAPI(); client = Anthropic()

@app.post("/chat")
async def chat(msg: str):
    r = client.messages.create(model="claude-sonnet-4-5",
                              max_tokens=1024, messages=[{"role": "user", "content": msg}])
    return {"reply": r.content[0].text}

# Mọi HTTP request + LLM call tự động tạo span
```



LLM Generate chiếm 67% latency. Muốn tối ưu → bắt đầu từ **LLM call**: model nhỏ hơn, prompt ngắn hơn, streaming hoặc parallelize RAG với LLM warmup.

Pattern 1: Sequential dependency

- $A \rightarrow B \rightarrow C$, tổng = sum
- Fix: parallelize A, B nếu không phụ thuộc

Pattern 2: N+1 queries

- Loop gọi API/DB nhiều lần
- Trace: nhiều span ngắn cùng tên
- Fix: batch API, hoặc pre-fetch

Pattern 3: Waiting (không phải CPU)

- Span dài nhưng CPU idle
- LLM API, DB, network
- Fix: parallelize, cache, timeout

Pattern 4: Retry storm

- Nhiều span retry trong 1 trace
- Backoff quá ngắn, không jitter
- Fix: exponential backoff, circuit breaker

Nhìn span dài nhất $\rightarrow$ hỏi “có parallelize được không?”. Nhìn nhiều span ngắn lặp $\rightarrow$ hỏi “có batch được không?”. Đó là 80% tối ưu hóa.

Tool	Strength	Best for	Pricing	OSS?
Langfuse	Full stack: tracing, eval, prompts, cost	Self-host, framework-agnostic	Free tier, cloud paid	Yes (MIT)
LangSmith	Tight LangChain, playground, datasets	LangChain users	Free tier, seat-based	No (SaaS)
Helicone	Proxy approach, 0 code change	Rapid integration	Free tier, usage-based	Yes (Apache)
Arize Phoenix	OpenTelemetry-native, OSS	Research, eval workflows	Free OSS	Yes (Apache)

Chọn **Langfuse** — open source, free cloud tier, framework-agnostic, đã support OTel GenAI conventions. UI tốt nhất cho LLM-specific features.

```
from langfuse.decorators import observe, langfuse_context
from anthropic import Anthropic
client = Anthropic()

@observe()
def rag_agent(query: str, user_id: str):
    langfuse_context.update_current_trace(user_id=user_id, tags=["prod", "rag"])
    docs = retrieve(query)
    response = client.messages.create(
        model="claude-sonnet-4-5", max_tokens=1024,
        messages=[{"role": "user", "content": f"Docs: {docs}\n\nQ: {query}"}])
    langfuse_context.update_current_observation(
        metadata={"doc_count": len(docs)},
        usage_details={"input": response.usage.input_tokens,
                       "output": response.usage.output_tokens})
    return response.content[0].text
```

Latency input/output cost (model pricing built-in) trace waterfall Xem ngay trên

Vấn đề: User phàn nàn agent chậm “đôi khi”. Metrics nói P95 = 2.3s, OK. P99 = 12s — không OK.

1. **Filter trace** theo duration > 10s trong 24h qua → được 47 traces
2. **Nhóm theo feature tag** → 42/47 thuộc feature "legal_qa"
3. **Mở waterfall** 1 trace: LLM span = 800ms (OK), RAG span = 10.2s (!)
4. **Drill vào RAG span:** sub-span vector_search = 9.8s với query length 4,200 tokens
5. **Root cause:** user dán full document vào query → embedding gọi với input lớn → chậm
6. **Fix:** truncate query to 500 tokens before embedding, thêm warning cho user

Không có trace → chỉ biết “đôi khi chậm”, không biết bước nào, không biết pattern nào. Với trace: **10 phút** từ bug report → root cause.

SLO-based Alerting & Dashboard

Metrics và traces chỉ có giá trị nếu có người nhìn — học design alert chất lượng dựa trên SLO

Cause-based (sai)

Alert về nguyên nhân kỹ thuật:

- CPU > 80%
- RAM > 90%
- Disk > 85%
- LLM API retry count > 5

Cause cao nhưng user không bị ảnh hưởng → false positive. Ignore dần.

Symptom-based (đúng)

Alert về impact tới user:

- P95 latency > SLO
- Error rate > 1%
- Cost/hour > budget
- Hallucination rate spike

Chỉ alert khi user thực sự bị ảnh hưởng. Ít false positive.

“Page on symptoms, not causes.” Cause alerts chỉ là supplementary info để debug sau khi symptom alert fire.

Vấn đề: Alert đơn giản “error rate > 1% trong 5 phút” → fire quá nhanh (noise) hoặc quá chậm (miss incident). **Giải pháp của Google:** kết hợp 2 windows với 2 burn rates:

Severity	Short window	Long window	Burn rate (vs SLO)	Ý nghĩa
Page (critical)	5 phút	1 giờ	14.4x	
Ticket (warn)	30 phút	6 giờ	6x	

“**14.4x burn rate**”: nếu error giữ mức này, tháng sẽ burn hết error budget trong 2 ngày thay vì 30.

Alert fire khi **cả 2 window** cùng vượt threshold. Short window → react nhanh với spike thực. Long window → filter noise ngắn. Google SRE Workbook Chapter 5.

Template cho mỗi alert:

- **Title rõ ràng:** “[P1] Agent P95 latency > 5s cho feature=summary”
- **Severity:** P1 (page ngay) / P2 (trong giờ hành chính) / P3 (ticket)
- **Impact statement:** “5% user đang bị chậm > 5s”
- **Current value:** “P95 = 6.3s, bình thường 1.8s, threshold 5s”
- **Dashboard link:** pre-filtered với feature tag, last 1h
- **Trace link:** top 10 traces chậm nhất trong window
- **Runbook link:** playbook fix step-by-step
- **On-call owner:** team/người chịu trách nhiệm

Lưu ý: Alert không có runbook = alert không thể xử lý lúc 3h sáng. Viết runbook là **một phần** của work “tạo alert”, không phải nice-to-have.

Metric	Threshold	Severity	Channel + Action
Latency P95	> 5s, 30 phút	P2 Warning	Slack, investigate trace
Error rate	> 5%, 5 phút	P1 Critical	Slack + PagerDuty, rollback
Hourly cost	> \$50 (budget × 2)	P2 Warning	Email, check users/features
Daily cost	> daily budget	P1 Critical	Email + SMS, kill switch
Tool call failure	> 10%, 15 phút	P2 Warning	Slack, check tool provider
Hallucination rate	> baseline +2 σ	P2 Warning	Slack, review outputs
Uptime	< 99%, 1 giờ	P1 Critical	PagerDuty, incident response

Alert phải **actionable**. Không biết phải làm gì → redesign hoặc bỏ. Alert nào không fire 90 ngày → bỏ.

Alert fatigue xảy ra khi

- quá nhiều alerts không quan trọng
- nhận alert 24/7, ngay cả đêm
- mọi người bắt đầu ignore
- alert thật bị lẫn trong noise
- team mất tin tưởng vào hệ thống

Cách tránh

- chỉ alert khi cần **hành động ngay**
- phân severity rõ ràng (P1/P2/P3)
- route đúng người, đúng channel
- review và tuning alerts hàng tuần
- auto-resolve khi metric recovery
- dedup trong window

Lưu ý: Nếu team ignore alerts thường xuyên, hệ thống alerting đang **tệ hơn không có alert** — alert thật sẽ bị miss. Ít alert chất lượng tốt hơn nhiều alert vô nghĩa.

Layer 1: Overview — Health status, uptime, key alerts

Cho leadership



Layer 2: Detail — 4 golden signals + Cost + Quality

Cho engineering



Layer 3: Drill-down — Individual traces, log search, root cause

Cho debugging

Mỗi stakeholder chỉ cần nhìn 1 layer. Leadership cần overview, không cần trace. Engineer cần drill-down, không cần revenue chart. Cùng 1 dashboard cho tất cả → không ai nhìn.

Latency P50/P95/P99
time-series

Traffic (QPS)
time-series

Error rate %
time-series + breakdown

Cost \$/hour
cumulative + forecast

Tokens in/out
stacked

Hallucination %
sampled, weekly

Nhiều panel hơn → không ai đọc. Giới hạn 6 panels ở layer 2 → nhìn 5 giây biết health status. Muốn chi tiết hơn → click vào layer 3.

Open source, powerful.

Kết nối mọi data source (Prom, Loki, Cloud-Watch).

Khi nào: team có infra ops, muốn kiểm soát

All-in-one SaaS.

Setup nhanh, alerting tốt, đắt ở scale.

Khi nào: cần nhanh, có budget, muốn 1 tool

LLM-native hoặc Python custom.

Full control, dễ customize.

Khi nào: AI agent MVP, demo, PoC

Lưu ý: Cho lab: **Langfuse dashboard** đã đủ cho MVP. Đừng dành thời gian build Grafana custom trước khi có đủ data — YAGNI principle.

1. **“Wall of metrics”** — 30 panels, không ai nhìn hết. Giới hạn 6–8 panels/layer.
2. **Time range mặc định quá dài** — default 1 giờ cho ops dashboard, không phải 1 tháng (che mất spike)
3. **Không có baseline/threshold line** — nhìn số $P95 = 2.1s$ không biết tốt hay xấu. Luôn vẽ đường SLO lên chart.
4. **Metric không có đơn vị/context** — “Cost: 1250” là gì? USD? ngày? Luôn label đầy đủ.
5. **Không auto-refresh** — dashboard cần realtime (15–30s refresh) cho ops. Cho monthly report thì khác.

Đưa dashboard cho người không trong team xem 30 giây → họ có nói được “hệ thống đang OK” hay “đang có vấn đề ở X” không? Nếu không, redesign.

Tools Landscape & Case Studies

Chọn tool đúng tiết kiệm tháng setup. Học từ case thực: Notion AI, Replit, và 7 anti-patterns từ industry

Category	Leader 2026	Strength	Watch
LLM-native	Langfuse, LangSmith	Prompt, eval, cost	Helicone, Phoenix
APM truyền thống	Datadog, New Relic	Infra + app + AI	Honeycomb, Lightstep
OSS self-host	Jaeger, Tempo, Loki	Zero vendor lock	SigNoz
Cost-focused	Helicone, OpenMeter	Token accounting	Vellum
Eval-focused	Arize Phoenix, Patronus	Quality & drift	Galileo

Converge: APM truyền thống (Datadog) add LLM features. LLM-native (Langfuse) add infra tracing. Trong 12 tháng tới, **OpenTelemetry GenAI semconv** thành chuẩn chung.

Q1: Team size?

- 1–5: SaaS, free tier
- 5–50: SaaS paid
- 50+: Hybrid / self-host

Q2: Compliance?

- HIPAA/PCI: self-host
- GDPR: EU region SaaS
- None: bất kỳ

Q3: Existing stack?

- Datadog: stay, add AI addon
- LangChain: LangSmith
- Agnostic: Langfuse

Q4: Budget/month?

- \$0: Langfuse cloud free
- \$100–500: LangSmith/Helicone
- \$500+: Datadog full stack

Q5: Skill set?

- Python-heavy: Langfuse
- Infra ops: Grafana
- Non-dev: Datadog

Q6: Evaluation?

- Quality cần: Phoenix, LangSmith
- Cost only: Helicone
- Full stack: Langfuse

Không có “best tool”. Có best tool **cho team + use case + budget của bạn**. Đừng copy stack của FAANG — họ có infra team 50 người.

Bối cảnh: Notion AI phục vụ hàng triệu user với nhiều features (summary, Q&A, writing assist). Cost OpenAI ban đầu $\sim 30\%$ revenue. **Monitoring insight:**

- 70% queries là “summarize” với prompt giống nhau
- 15% user chiếm 60% cost (power users với doc dài)
- Regenerate rate cao ở feature “writing assist”

Actions taken (theo thứ tự ROI):

1. Prompt cache cho system prompt (tất cả features) → giảm 40% input cost
2. Route “summary” qua model nhỏ hơn (Haiku tier) → giảm 60% cost cho feature này
3. Per-user rate limit cho free tier → limit abuse power users
4. Improve prompt cho “writing assist” → giảm regenerate 35%

Total cost / MAU giảm **58%** trong 3 tháng, không giảm quality metrics. Điều làm được vì có monitoring chi tiết theo feature + user + model.

Bối cảnh: Replit AI code assistant, user báo “suggestions bị tệ hơn tuần trước”. Engineering metrics đều xanh. **Monitoring insight:**

- Regenerate rate tăng từ 12% → 23% trong 2 tuần (implicit signal!)
- Thumbs-down rate tăng chậm hơn (user ít bấm)
- Đặc biệt cho ngôn ngữ python và javascript

Investigation (bằng trace):

- Filter trace cho regenerate cases → context truncation happening
- Thay đổi tokenizer version tuần trước → đếm tokens khác 10%
- Truncation threshold không được update → cut off giữa câu

Revert tokenizer, thêm integration test cho token counting. Lesson: **implicit signals** (regenerate) là early warning, explicit signals (thumbs down) quá chậm. Cả 2 đều cần.

1. **“We’ll add monitoring later”** — later = never. Add ngay từ MVP.
2. **Log full prompts và responses** — vi phạm GDPR, storage bill lên trời. Sanitize + sample.
3. **Alert trên mọi metric “quan trọng”** — 50 alerts → alert fatigue → ignore.
4. **Không có runbook** — alert fire lúc 3h sáng, engineer trẻ lost, escalate lên senior.
5. **Monitoring dev $\neq$ prod config** — prod có issue không reproduce được vì dev khác setup.
6. **Chỉ đo performance, quên cost** — đến cuối tháng mới biết đốt tiền.
7. **Trust vendor mặc định** — LangChain default telemetry có thể log sensitive data. Đọc docs trước khi deploy.

Lưu ý: Anti-pattern #1 là phổ biến nhất và tai hại nhất. Monitoring không phải là feature phụ → là phần **core** của production system, ngang với authentication.

Lab 13 & Closing

Monitoring đầy đủ cho agent: biết nó chạy thế nào mà không cần hỏi user, và có blueprint bàn giao được

07

Gắn monitoring stack đầy đủ vào deployed agent từ Day 12: structured logging + tracing + dashboard + SLO-based alerts, với blueprint document bàn giao được.

Phase A: Instrumentation (30 phút)

1. Setup Langfuse project (free cloud tier), lấy API keys
2. Add structlog cho structured JSON logging + correlation ID với contextvars
3. Integrate Langfuse `@observe()` decorator cho 3 functions chính
4. Add tags: `user_id`, `feature`, `model`, `env`

Phase B: Dashboard + Alerts (30 phút)

5. Define SLO: P95 latency, error rate, daily cost budget
6. Build dashboard Layer 2 (6 panels tối thiểu)
7. Configure 3 alert rules với runbook links

Phase C: Validation (30 phút)

8. Gửi 10–20 requests variety → check traces xuất hiện
9. Inject 1 failure (bad prompt) → verify alert fire
10. Viết blueprint document (1 trang: SLO, architecture, playbook)

Triệu chứng	Cách xử lý
Trace không xuất hiện ở Langfuse Cost không được track	Check API key env var, network, bật LANGFUSE_DEBUG=true Model name sai (phải khớp Langfuse pricing DB) hoặc thiếu usage_details
Correlation ID không propagate qua async PII leak vào log dù đã scrub	Dùng contextvars; kiểm tra clear_contextvars ở đầu mỗi re- quest Check order processors: scrubber phải chạy trước JSONRen- derer
Alert fire nhưng không Slack Dashboard trống dù có traces	Check webhook URL, quota rate limit, severity routing rules Time range filter, tag filter, hoặc data source chưa kết nối

Bật DEBUG cho langfuse và opentelemetry logger → thấy trace export request/response, tìm ra vấn đề trong 5 phút.

Logging & Tracing (40%)

- Structured JSON logs (10)
- Correlation ID propagate (10)
- PII sanitized (10)
- 10+ Langfuse traces (10)

Blueprint document (20%)

- SLO table (5)
- Architecture diagram (5)
- Alert playbook (5)
- Cost & scaling plan (5)

Dashboard & Alerts (40%)

- 6+ panels Layer 2 (15)
- SLO defined (5)
- 3 alert rules với runbook (15)
- Screenshot có data (5)

Điểm bonus (+10)

- Cost optimization (prompt cache)
- Quality metric (heuristic-based)
- OTel auto-instrument HTTP

Những ý chính cần nhớ trước khi sang bài tiếp theo

- 1 **3 pillars + 2 extras.** Metrics, Logs, Traces + **Cost** và **Quality** riêng cho AI.
- 2 **SLO-driven, symptom-based alerting.** Alert khi user bị ảnh hưởng, luôn có runbook.
- 3 **OpenTelemetry + FinOps.** Instrument 1 lần; 4 cost patterns (cache/routing/semantic/batch) giảm 70%.

AI Evaluation & Benchmarking

*“Sếp hỏi: AI agent tốt hơn ChatGPT bao nhiêu? Bạn nói sao nếu không có benchmark? Monitoring đo **đang hoạt động thế nào**, evaluation đo **có tốt không**. ”*

- Chuẩn bị: 10 câu hỏi mẫu với expected answers cho agent, cover các edge cases
- Đọc trước: RAGAS documentation — faithfulness, answer_relevancy, context_precision (20 phút)
- Suy nghĩ: quality metric nào quan trọng nhất cho use case của bạn? Vì sao?

1. Google SRE Workbook, *Alerting on SLOs* — sre.google/workbook. Multi-window multi-burn-rate alerting, error budget.
2. Langfuse, *Open Source LLM Observability* — langfuse.com. Tracing, cost tracking, prompt management, eval.
3. LangSmith Documentation — docs.smith.langchain.com. Tracing, evaluation, datasets, monitoring.
4. OpenTelemetry, *GenAI Semantic Conventions* — opentelemetry.io/docs/specs/semconv/gen-ai. Vendor-neutral standard cho LLM tracing.
5. Microsoft Presidio — microsoft.github.io/presidio. PII detection & anonymization SDK.
6. Charity Majors, *Observability Engineering* (O'Reilly 2022) — quyển sách nền tảng về observability hiện đại.
7. Anthropic, *Prompt Caching Best Practices* — docs.anthropic.com/prompt-caching. Giảm 70% cost.

Hỏi & Đáp

*Monitoring tốt nghĩa là bạn biết agent có vấn đề **trước khi** user phàn nàn — và có đủ data để fix **trong phút**, không phải giờ.*